

Erdbebenerkennung in laborischen Experimenten

Gamze Fıçı
Türkisch-Deutsche Universität

Juni 2020

Abstract

In den letzten Jahrzehnten hat das Volumen seismischer Daten exponentiell zugenommen, so dass effiziente Algorithmen zur zuverlässigen Erkennung und Lokalisierung von Erdbeben erforderlich sind. Die ausgefeiltesten Methoden von heute durchsuchen die Fülle kontinuierlicher seismischer Aufzeichnungen nach sich wiederholenden seismischen Signalen. Die Vorhersage von Erdbeben ist aufgrund ihrer verheerenden Folgen eines der wichtigsten Probleme der Geowissenschaften. Aktuelle wissenschaftliche Studien zur Erdbebenvorhersage konzentrieren sich auf drei wichtige Punkte: Wann wird das Ereignis eintreten, wo wird es eintreten und wie groß wird es sein.

1 Einführung

Die Erdbebenseismologie ist ein wichtiges Thema für das Verständnis der Gefahren durch natürliche und induzierte Erdbeben sowie für das Verständnis der physikalischen Eigenschaften der Erdkruste. In den letzten zehn Jahren hat die Anzahl der seismischen Überwachungsstationen dramatisch zugenommen, was dazu führte, dass das Forschungsgebiet von einer beobachtungsbasierten Wissenschaft zu einer datengetriebenen Wissenschaft überging. Durch die Schätzung zukünftiger Erdbeben können Schäden dank der Maßnahmen, die ergriffen werden können, minimiert werden. Wenn diese Herausforderung gelöst ist und sich die Physik letztendlich vom Labor auf das Feld skaliert, haben die Forscher das Potenzial, die Bewertung der Erdbebengefahr zu verbessern, wodurch Leben und Milliarden von Dollar an Infrastruktur gerettet werden könnten. In diesem Artikel befasste ich mich der Erdbebenerkennung und Erdbebenvorhersage in der Labormessung. Ich denke, dies ist ein guter Anfang, um an echten Erdbeben implementieren zu können.

2 Verwandte Arbeit


Ein Wettbewerb wurde mit Kaggle verwirklicht. In diesem Wettbewerb haben die Menschen angesprochen, wann das Erdbeben stattfinden wird. Insbesondere haben sie die verbleibende Zeit bis zum Auftreten von Laborerdbeben anhand seismischer Echtzeitdaten vorhergesagt.

Laut [2] (steht unten) wird NuSVR gegen dieses Problem benutzt. NuSVR für die Regression wurde mit Libsvm implementiert, wobei ein Parameter zur Steuerung der Anzahl der Unterstützungsvektoren verwendet wurde. Wie SVR versucht NuSVR, die größte Marge zu finden. Als Loss Funktion wurde Mean Absolute Error gewendet und Score ist 2.321.


Laut dem von verwendeten Kaggle Neural Network [5] (steht unten) beträgt der MAE-Wert 2.203.

3 Datensatz

Dies ist eine Ansicht des gesamten Datensatzes(rund 630 Million).



Akustische Daten und Zeit bis zum Ausfall: 1% abgetastete Daten.



Es gibt einen Punkt vor dem eigentlichen Erdbeben (blaue Linie), an dem die seismografische Aktivität der akustischen Aktivität ansteigt.

	acoustic_data	time_to_failure
0	12	1.4690999832
1	6	1.4690999821
2	8	1.4690999810
3	5	1.4690999799
4	8	1.4690999788

Das akustische Daten Eingangssignal(acoustic data) wird verwendet, um die verbleibende Zeit vor dem nächsten Laborerdbeben (time to failure) vorherzusagen.

- Acoustic data - das seismische Signal
- Time to failure - die Zeit (in Sekunden) bis zum nächsten Laborerdbeben
- seg_id - die Testsegment-IDs, für die Vorhersagen getroffen werden sollen (eine Vorhersage pro Segment)

4 Methods

Ich habe MAE als Loss Funktion benutzt. Je niedriger der Wert der Loss-Funktion ist, desto besser ist die Leistung des Modells. Auf diese Weise können wir interpretieren, wie gut das Modell im Trainingssatz ist. Der absolute Fehlerwert wird berechnet, indem die Summe der Fehler berechnet wird, die in jeder Stichprobe im Trainingssatz gemacht wurden. Wenn wir diese Summe durch die Anzahl der Daten teilen, ist die gebildete Zahl der mittlere absolute Fehler.

Deep Sequential Neural Network


Ich habe im Endgabericht Deep Learning Neural Network implementiert. Als Loss Funktion habe ich Mean Absolute Error gewendet und mein Score ist 2.2745. Das ist viel besser als das Ergebnis, das ich mit NuSVR erzielt habe.

5 Hyperparameter

- Adam als Optimization Algorithmus (Learning rate = 0.0001)
- 500 als Epoch-Größe
- 64 als Mini Batch-Größe
- Dropout 0.3 in jeder Schicht
- MAE (Mean Absolute Error) als Loss-Funktion
- ReLu (Rectified Linear Unit) als Activation-Funktion
- 4 Schicht im Deep Layer Neural Network

6 Ergebnisse

Ich habe verschiedene Keras Neural Network-Modellbeispiele untersucht und mein eigenes Neural Network Modell erstellt. Wenn wir uns das Ergebnis ansehen, können wir interpretieren, dass der Loss-Wert schrittweise abnimmt.



7 Zukünftige Arbeit

Um eine bessere Leistung zu erzielen, können mehrere Modelle statt ein Modell mit guter Leistung kombiniert und ausprobiert werden. Nach [3] wird MAE Score sinkt, wenn mehrere Modell benutzt wird. Danach können Studien mit realen Erdbebendatensätzen durchgeführt werden.

8 Code

Der hier beschriebene Code ist verfügbar unter <https://github.com/gamzef/INF003>.

9 References

- [1] *LANL Earthquake Prediction* (2018). Kaggle.
<https://www.kaggle.com/c/LANL-Earthquake-Prediction/overview>
- [2] Reade, Walter. (2018) *Basic Feature Benchmark*. Kaggle.
<https://www.kaggle.com/inversion/basic-feature-benchmark/data>
- [3] Semenov, A. (2019) *130th private LB ideas*. Kaggle.
<https://www.kaggle.com/alexsemenov/130th-private-lb-ideas-35th-on-public-lb/data>
- [4] Preda, G. (2019) *LANL Earthquake EDA and Prediction*. Kaggle.
<https://www.kaggle.com/gpreda/lanl-earthquake-eda-and-prediction>
- [5] Gupta, A. (2019) *Lanl Catboost and Keras NN*. Kaggle.
<https://www.kaggle.com/roydatascience/lanl-lightgbm-and-keras-nn/data>